

LAPORAN TUGAS AKHIR

IF5250 DEEP LEARNING

ENVIRONMENTAL SOUND CLASSIFICATION WITH CRNN, RESNET-18 MEL-SPECTROGRAM, AND VISION TRANSFORMER

Disusun untuk memenuhi tugas mata kuliah IF5250 *Deep Learning* yang diampu oleh Nugraha Priya Utama, S.T., M.A., Ph.D.

Nama : Siti Ramadina Goethe Kesumah.

NIM : 15322001

Dengan mengumpulkan tugas ini, saya menyatakan bahwa:

1. Tugas ini adalah hasil kerja saya sendiri.
2. Saya tidak melakukan plagiarisme dari sumber manapun.
3. Semua referensi telah dicantumkan dengan benar.
4. Saya memahami konsekuensi pelanggaran integritas akademik.

Bandung, 03 Juni 2026

Siti Ramadina Goethe K.

(15322001)



**PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
2026**

I. Pendahuluan

Klasifikasi suara merupakan proses identifikasi dan pengelompokan suara di lingkungan sekitar dengan memanfaatkan arsitektur *artificial intelligence*, seperti ResNet-18 Mel-Spectrogram, *Convolutional Recurrent Neural Network* (CRNN), atau Vision Transformer (ViT). Pemantauan suara lingkungan menjadi krusial di tengah perkembangan urbanisasi dan perubahan iklim, karena kegunaannya dalam mengidentifikasi kebisingan demi meningkatkan kualitas lingkungan dan kesehatan masyarakat (Wibowo, 2025). Aplikasi lainnya banyak diterapkan dalam pemantauan keamanan *smart city*, mendeteksi kerusakan mesin, mengetahui aktivitas ilegal di dalam hutan beserta suara satwa eksisting (Fadhillah & Sumiharto, 2023), dan sebagai sistem peringatan bagi penyandang gangguan pendengaran (Ignatius, 2026), dan berpotensi dalam mendeteksi kerusakan bangunan (Khan, 2018) atau mesin (Pichler et al., 2025). Suara lingkungan yang berbeda dengan pengenalan ucapan (*speech recognition*) memiliki karakteristik stokastik (acak dan tidak stasioner) yang berarti suara ini tidak memiliki struktur fonen yang jelas atau bahkan aspek ritme dan melodi (Bansal & Garg, 2022).

Dalam lingkup *deep learning*, terdapat banyak rekomendasi penggunaan model *artificial intelligence* untuk melakukan tugas klasifikasi suara lingkungan, salah satunya seperti Audio Spectrogram Transformer yang diusulkan oleh Gong et al. (2021). Model ini digolongkan sebagai *state-of-the-art* dalam domain klasifikasi suara karena menerapkan ViT yang dalam mengekstraksi suara dalam bentuk spektrogram (gambar). Di sisi lain, CRNN menawarkan pendekatan hibrida yang memanfaatkan pemetaan fitur dari CNN sebagai *backbone* dengan pelacakan pola temporal dari LSTM atau GRU. Sementara itu, ResNet-18 yang merupakan versi sederhana dari CNN memanfaatkan spektrogram sebagai gambar akustik yang statis untuk mengekstrak fitur visual secara hierarkis.

Tugas akhir mata kuliah IF5250 *Deep Learning* ini dilaksanakan untuk melakukan perbandingan (*benchmarking*) antar ketiga model tersebut dengan menggunakan dataset ESC-50. Penggunaannya adalah CRNN sebagai arsitektur utama, ResNet-18 sebagai arsitektur *baseline*, dan ViT sebagai model SoTA. Perbandingan dari ketiga arsitektur ini akan dijadikan sebagai tuntunan dalam memilih arsitektur terbaik dalam penerapan pengolahan sinyal suara dari lingkungan. Berikut adalah beberapa tujuan yang ingin dicapai dalam tugas ini.

1. Mengimplementasikan model utama CRNN untuk klasifikasi 50 kelas suara.
2. Membandingkan performa model utama terhadap dua model pembanding.

3. Menganalisis kesesuaian representasi internal antar-arsitektur (Representational Similarity Analysis, RSM) untuk melihat proses pengelompokkan suara dari setiap model.
4. Mengidentifikasi area fokus (atensi) model melalui visualisasi *saliency maps* pada spektrogram untuk memahami karakteristik frekuensi yang dianggap penting oleh masing-masing arsitektur.

Adapun kontribusi dari tugas akhir ini adalah sebagai berikut.

1. Studi komparatif, yaitu perbandingan ketiga model dari sisi akurasi, jumlah parameter, dan efisiensi inferensi pada domain audio.
2. Analisis representasi, yaitu menghasilkan matriks kemiripan representasi (RSM) dari setiap model dalam membedakan kelas suara yang mirip.
3. Dokumentasi reproduibel, yaitu menyediakan repositori kode yang mencakup seluruh alur kerja mulai dari prapemrosesan audio menjadi Mel-Spectrogram hingga tahap evaluasi akhir.

Struktur laporan ini terdiri dari delapan bab utama yang mencakup pendahuluan, tinjauan pustaka, metodologi eksperimen, hasil *benchmarking*, analisis RSM dan *saliency*, serta diskusi komparatif yang mengaitkan hasil eksperimen dengan prinsip-prinsip pemrosesan suara sebelum ditutup dengan kesimpulan.

II. Tinjauan Pustaka

II.1 Arsitektur CRNN

Arsitektur CRNN merupakan konsep hibrida yang mengkombinasikan arsitektur dasar konvolusi (CNN) untuk tugas ekstraksi fitur dan *recurrent* (RNN) untuk menangani ketergantungan temporal dari data suara. Sinyal suara tidak dapat langsung diproses dalam CRNN, tetapi perlu dilakukan konversi ke dalam bentuk visual untuk merepresentasikan frekuensi pada waktu tertentu. Gelombang suara dari data mentah diubah ke dalam bentuk mel-spektrogram sebagai upaya ekstraksi fitur. CNN yang terdiri dari lapisan konvolusi, *pooling*, dan *fully connected*, pada awalnya akan menerima visual tersebut dalam wujud gambar *grayscale* (sinyal *noise* tunggal) atau *multichannel* yang memiliki tensor dengan bentuk (*Batch*, *Channels*, *Height*[*frequency*], *Width*[*time*]). Kemudian *input* tersebut akan di alirkan pada lapisan konvolusi yang mengandung

kernel untuk melakukan perkalian dot antara kernel dengan *input*. Berikut adalah susunan lebih lanjut dari arsitektur konvolusi (Ruan et al., 2022).

1. Lapisan konvolusi

Dari arsitektur model CNN ini, struktur audio dapat diekstraksi melalui representasi spektrogram yang secara visual menunjukkan waktu (sumbu-x), frekuensi (sumbu-y), dan amplitudo (warna atau kecerahan). Visual yang merepresentasikan matriks ini dapat difilter untuk mendeteksi naik-turunnya nada sehingga jenis suara apapun dapat dibedakan dengan mudah. Selain itu, penggunaan fungsi aktivasi non-linear mendorong CNN untuk mempelajari batas akustik yang sangat kompleks dan benuansa.

Hasil keluaran dari setiap lapisan konvolusi dengan persamaan beserta fungsi aktivasi yang digunakan (contoh ReLU dengan kecepatan pelatihannya yang menjanjikan) dapat dinyatakan sebagai berikut.

$$y = f(k * x + b)$$

$$ReLU(z) = \max(0, z)$$

dengan:

k = matriks kernel/filter

D = jumlah kernel

x = matriks input (tensor)

$m \times n$ = ukuran kernel

$H \times W$ = ukuran matriks input

z = parameter *input* untuk fungsi aktivasi

b = matriks bias

f = fungsi aktivasi

Lalu, ukuran dari *output* lapisan konvolusi dapat dihitung menggunakan persamaan berikut.

$$(H - m + 1) \times (W - n + 1) \times D$$

Semakin dalam lapisan tersebut digunakan, maka semakin tinggi pula tingkat abstraksi dari fitur yang diekstraksi. Biasanya penggunaan *batch normalization* juga dapat mengiringi penggunaan fungsi aktivasi setelahnya.

2. Lapisan *pooling*

Lapisan dengan fungsi non-linear ini biasanya diletakkan di setiap akhir lapisan konvolusi untuk mencegah terjadinya data yang redundan dari hasil konvolusi sehingga hanya menghasilkan informasi penting saja. Penerapan *pooling* ini mampu mengurangi beban komputasi dan membuat CNN mampu mendeteksi pola spesifik dari suatu suara walaupun

dimulainya suara tersebut tidak selalu dari awal rekaman. Selain itu, lapisan ini berguna untuk mengurangi dimensi dari data dan mencegah terjadinya *overfitting*.

3. Lapisan *fully-connected*

Setiap lapisan terakhir akan terhubung dengan setiap neuron. Hasil ekstraksi fitur yang sebelumnya akan diratakan (*flattened*) menjadi bentuk vektor satu dimensi sebagai *input* lapisan *fully-connected* ini. Lapisan ini diakhiri dengan tugas prediksi final untuk menentukan jenis suara melalui penggunaan fungsi aktivasi (biasanya *softmax*).

Sementara itu, RNN yang berperan sebagai model yang mengagregasikan pola temporal dari data audio berperan dalam mengekstraksi *output* dari CNN dan menangkap memori dari audio tersebut berdasarkan urutan dan waktu dari akustik. Audio yang mengandung melodi, ritme, atau terkadang kata-kata didefinisikan sebagai banyaknya perubahan frekuensi sepanjang waktu. Analisis audio tanpa melibatkan ketergantungan temporal dapat menghilangkan narasi atau konteks dari suara tersebut (Conway et al., 2018). Selain itu, penggunaan model sekuensial seperti RNN mampu mengatasi kejadian yang saling tumpang tindih dalam lingkungan yang sesungguhnya (Nogueira et al., 2022).

Model AI yang bisa digunakan adalah dalam bentuk Bi-directional, yaitu BiLSTMs atau BGRUs yang memungkinkan proses lapisan memproses audio baik dari arah *forward* maupun *backward* untuk membuat model mampu mengenali konteks audio secara keseluruhan. Sebelum masuk ke dalam arsitektur RNN, audio akan dilakukan *reshaping* dari *output* CNN terlebih dahulu menjadi urutan waktu. Sebagai *output*, RNN akan menghasilkan keadaan akhir dari sekuens tersebut menjadi klasifier terakhir untuk penentuan kategori suara.

II.2 Arsitektur ResNet-18 Mel-Spectrogram

Pemanfaatan arsitektur ResNet-18 dapat diperluas dari klasifikasi gambar hingga sekarang audio. Arsitektur ini merupakan versi sederhana dari CNN dengan penerapan blok residual untuk mencegah terjadinya penyusutan gradien saat mekanisme *backpropagation* seiring bertambahnya jumlah lapisan jaringan saraf. Blok residual ini dinamakan sebagai *shortcut connection* atau *skip connection* yang membuat jaringan untuk fokus mempelajari fitur kompleks yang tersisa dengan tetap mempertahankan informasi penting dari lapisan sebelumnya. Hal ini dinyatakan dalam formula matematis berikut.

$$y = f(x) + x$$

ResNet-18 memiliki satu lapisan konvolusi di awal yang diikuti dengan 8 blok residual dengan setiap bloknnya terdapat lapisan konvolusi lagi, lalu diakhiri dengan lapisan *fully-connected*. Dalam tugas ini, perannya sebagai model *baseline* dirasa cocok karena kemampuannya yang cukup ideal dalam memahami pola rumit dengan tetap menggunakan sumber daya pelatihan yang tidak terlalu berat. Pada tugas klasifikasi suara lingkungan, audio yang diberikan akan ditransformasi terlebih dahulu menjadi *Short-Time Fourier Transform* untuk memetakan frekuensi terhadap waktu. Lalu, frekuensi tersebut akan diubah dalam bentuk skala mel. Perubahan amplitudo dalam bentuk skala desibel mampu membuat beberapa bentuk suara menjadi pola tertentu yang lebih unik dan lebih penting. ResNet-18 yang asli menerima *input* gambar berwarna (*Channel 3*), sedangkan *input mel-spectrogram* hanya berupa *grayscale* (*Channel 1*). Oleh karena itu, modifikasi penerimaan *channel* tersebut akan dilakukan pada *input layer* di awal.

II.3 Arsitektur Vision Transformer Audio

Arsitektur ViT yang dikhususkan untuk menangani tugas audio merupakan pendekatan yang paling modern (SoTA). Mekanisme kerjanya memanfaatkan atensi secara global untuk mendapatkan informasi secara luas dari konteks yang diberikan, tidak seperti CNN yang hanya menangkap secara lokal saja. Dalam ViT diperkenalkan istilah *self-attention* yang memungkinkan model dapat berinteraksi langsung terhadap setiap bagian spektrogram sehingga hubungan dari banyak kejadian atau adanya suara dari jauh dapat segera dikenali lebih efisien dibandingkan penggunaan CNN yang hanya dapat memperoleh informasi lengkap setelah melewati banyak lapisan konvolusi. Arsitektur ViT memperkenalkan mekanisme *patching* yaitu memotong spektrogram menjadi bagian-bagian kecil (*patches*) untuk diratakan (*flatten*) menjadi sebuah vektor angka atau penggalan kata yang dinumerikkan (*token*). Karena kejadian yang berlangsung secara paralel ini, ViT kehilangan informasi posisi, padahal urutan waktu dalam data audio tetaplah penting. Untuk mengatasi ini, *positional encoding* ditambahkan dalam setiap token untuk membuat model bisa memahami struktur temporal dan spektral.

II.4 Mel-Spectrogram and Brain Encoding

Brain encoding merupakan model komputasi yang dirancang untuk memprediksi respon saraf berdasarkan rangsangan eksternal. Studi ini mempelajari representasi internal dalam model jaringan saraf buatan yang mencerminkan aktivitas saraf di otak manusia saat diberikan rangsangan

yang sama. Jika diulik dari sisi audio, otak manusia menangkap gelombang suara dan mengubahnya dalam sinyal listrik (impuls). Kemampuan inilah yang dijadikan ide dasar dalam pengembangan *deep neural networks* (DNNs) untuk melakukan tugas klasifikasi suara. Alih-alih menggunakan spektogram standar yang berupa frekuensi linear dan dinyatakan dalam Hertz, pemodelan klasifikasi suara lebih mengutamakan menggunakan spektogram dalam skala mel (atau disebut sebagai mel-spektogram). Jenis spektogram ini memungkinkan pemetaan frekuensi ke dalam skala logaritmik yang mampu meniru proses penerimaan nada pada telinga manusia dan memungkinkan kompresi resolusi frekuensi yang lebih baik dibandingkan spektogram standar.

Secara hierarkis sistem pendengaran manusia merupakan mekanisme yang kompleks, mulai dari penangkapan rangsangan dari telinga luar hingga pengaliran sinyal informasi ke dalam korteks serebral. Perolehan suara ini diterima oleh bagian luar telinga terlebih dahulu, lalu masuk ke telinga dalam yang kemudian dilakukan konversi sinyal suara menjadi frekuensi di dalam koklea. Informasi frekuensi ini dikirim melalui Korteks Auditori Primer (A1) yang prosesnya mirip dengan CNN pada lapisan awal mendeteksi pola sederhana di spektogram. Selanjutnya, suara diproses tingkat tinggi di dalam Superior Temporal Gyrus (STG) untuk pengenalan jenis suara lebih lanjut. Sementara itu, dari sisi algoritma *deep learning*, aktivitas di saraf auditori dikorelasikan dengan lapisan di awal di model dan kegiatan tingkat atas dikorelasikan dengan lapisan saraf buatan yang semakin dalam. Model dengan arsitektur konvolusi ataupun rekurens memiliki karakteristik bentuk yang mirip dengan otak biologis, tetapi dalam pelaksanaannya, model ViT tetap menawarkan kemampuan yang lebih tinggi terkait akurasi dan efisiensi pelatihan. Kemiripan antara jaringan biologis dengan jaringan saraf buatan dapat ditinjau dari beberapa aspek berikut.

Tabel II.1 Korelasi antara otak biologis dan jaringan saraf buatan dalam memproses suara (Li et al., 2023; Giordano et al., 2023)

Aspek	Jaringan Biologis (Otak)	Jaringan Saraf Buatan
Pemrosesan hierarkis yang dibagi menjadi pemrosesan tingkat rendah (sebagai dasar analisis nada, volume, dan frekuensi) dan tingkat tinggi (huruf vokal, kata, dan makna dari suara).	Tingkat rendah: auditori dan <i>midbrain</i> . Tingkat tinggi: Otak.	Tingkat rendah: Lapisan bawah atau spektogram. Tingkat tinggi: jaringan saraf yang lebih dalam untuk ekstraksi fitur yang lebih abstrak
Fungsi non-linear	Neuron melepaskan impuls listrik saat sinyal suara	Penggunaan fungsi aktivasi non-linear, seperti ReLU atau

Aspek	Jaringan Biologis (Otak)	Jaringan Saraf Buatan
	melewati ambang batas tertentu dengan bergantung pada pola non-linear.	Tanh untuk melewatkan informasi penting dari fitur pada lapisan yang berikutnya.
Adaptasi kontekstual	Keduanya memiliki kemampuan adaptasi dalam perubahan pola suara akibat adanya kebisingan di latar dan segera mengisolasi sinyal yang terpenting saja.	
Penyelarasan Matematis	Melalui RSA, pemetaan fungsi otak oleh fMRI/iEEG dan jaringan saraf buatan memiliki aktivasi geometri yang berkaitan erat dengan aktivasi pada <i>superior temporal gyrus</i> .	

II.5 Representation Similarity Analysis (RSA)

Representation Similarity Analysis merupakan sebuah kerangka kerja komputasional untuk menganalisis perbandingan antara representasi internal dari arsitektur model yang berbeda, atau dengan representasi aktivitas biologis yang sesungguhnya. Penerapannya dalam tugas ini sangat berkaitan erat dengan *brain encoding* sebelumnya. Matriks RSA (RSM) dapat diperoleh dari paper terkait lalu dibandingkan dengan model yang digunakan dalam tugas ini untuk diperoleh kecocokan metodenya. Jika korelasinya semakin tinggi, maka menandakan bahwa representasi yang dilakukan oleh model sudah baik dan mendekati kemampuan otak biologis aslinya. RSA dibagi menjadi dua konsep utama, yaitu representasi geometri yang mampu menyimpan informasi model dalam vektor *embedding* dan *cosine similarity* yang digunakan untuk menentukan orientasi suatu vektor yang menggambarkan fokus frekuensi/waktu dari model terhadap suara yang diberikan. Kedua konsep ini biasanya disajikan dalam bentuk matriks dengan ukuran $N \times N$ atau visualisasi *heatmap*. Perbandingan RSM ini perlu dilakukan antar masing-masing kedua model untuk mengatasi tugas perbandingan yang tidak dapat dilakukan langsung karena bentuk arsitekturnya yang berbeda jauh. Jika kedua model memiliki RSM yang sama, maka keduanya memiliki pandangan yang sama dalam memahami data audio yang diberikan. Setiap kotak kecil dalam RSM akan diisi dengan nilai *cosine similarity* yang dapat dihitung melalui rumus berikut.


$$RSM_{i,j} = \frac{e_i \cdot e_j}{\|e_i\| \cdot \|e_j\|}$$

dengan e_i dan e_j adalah vektor *embedding* dari sampel ke- i dan ke- j pada lapisan *penultimate*, yaitu lapisan terakhir sebelum *output*.

III. Metodologi

III.1 Data dan Tahap Prapemrosesan

Pada eksperimen ini, digunakan dataset berbasis audio dari ESC-50 yang diperoleh dari GitHub milik Piczak (2015). Dataset yang berupa 2000 data suara lingkungan ini terdiri dari 50 kelas sematik dengan 40 contoh di setiap kelasnya, dan setiap sampel audio memiliki durasi rekaman selama 5 (lima) detik. Dataset ini dibagi menjadi 5 (lima) kategori kelas utama, yaitu *animals*, *natural soundscapes & water sounds*, *human non-speech sounds*, *interioir/domestic sounds*, dan *exterior/urban noises*. Dataset ini dapat digunakan secara otomatis melalui *platform* Kaggle, lalu dilakukan konversi pada mel-spektrogram dan log-mel spektrogram, kemudian kelas khusus ESC-50 juga dibuat. Berikut adalah beberapa contoh representasi visual dari suara (spektrogram).



Gambar III.1 Contoh visualisasi spektrogram dari suara *hen*, *drinking sipping*, *insects*, *washing machine*, *fireworks*, dan *hand saw* (ESC-50, Piczak, 2015)

Tahap konversi dataset ESC-50 dalam representasi log-Mel spektrogram tersebut dilakukan melalui transformasi dengan Mel *filter bank* sebanyak 128 kanal frekuensi, 1.024 ukuran jendela, dan pergeserannya sebesar 512 sampel. Penggunaan skala log ini dimaksudkan karena pendekatannya terhadap karakteristik pendengaran manusia pada umumnya. Hasil akhir konversi yang akan digunakan pada *input* model menunjukkan bahwa log-Mel spektrogram memiliki ukuran 128 x 216.

Dataset yang rerata berada pada 22,05 kHz ini perlu dibagi menjadi beberapa partisi sama banyak (*fold*) untuk memisahkan fungsionalitas data, seperti *fold* 1-3 digunakan untuk keperluan pelatihan model (*training*), *fold* 4 untuk validasi data, dan *fold* 5 untuk evaluasi terakhir. Berikut adalah informasi awal data yang digunakan beserta pembagiannya.

Tabel III.1 Informasi awal partisi data

Jumlah data latih (<i>training</i>)	1.200
Jumlah data validasi (<i>validation</i>)	400
Jumlah data uji (<i>test</i>)	400
Ukuran <i>batch input</i>	([32, 1, 128, 431])
Ukuran <i>batch label</i>	([32])

Berdasarkan pembagian data tersebut, SpecAugment yang merupakan teknik augmentasi dalam pemrosesan data audio atau *speech recognition*, diterapkan untuk memberikan variasi yang lebih beragam pada saat pelatihan model. Teknik ini diharapkan dapat membuat proses komputasi menjadi lebih efisien, mencegah model mengalami *overfitting*, dan meningkatkan kinerja model tanpa menambah waktu pelatihan (Soni et al., 2024). SpecAugment memodifikasi spektrogram secara visual (bukan melalui data mentah audio) dan memacu jaringan saraf untuk lebih tangguh dalam menghadapi deformasi waktu atau hilangnya sebagian informasi frekuensi sehingga model tidak lagi bergantung pada rentang frekuensi atau waktu tertentu (Park & Chan, 2019). Jenis augmentasi yang digunakan adalah *Frequency Masking* dengan parameter lebar maksimum area frekuensi yang dihapus (*masking*) sebesar 15 bin frekuensi, serta *Time Masking* dengan parameter panjang maksimum segmen waktu sebesar 40 *frame* waktu.

III.2 Arsitektur Model

Setiap model memiliki karakteristik unik dari arsitekturnya masing-masing. Berikut adalah deskripsi arsitektur dari setiap model.

III.2.1 CRNN

Secara garis besar, arsitektur CRNN terdiri dari tahapan pemanfaatan data mel-spektrogram hasil konversi sebelumnya ($Ch = 1, mel_bins = 128, time_frames = 216$) menjadi *input* model, ekstraksi fitur dengan CNN, pembuatan *feature map* hasil ekstraksi fitur, transformasi bentuk menjadi data berbentuk *sequence* sebelum masuk ke dalam RNN, hingga berakhir pada tugas klasifikasi atau prediksi dengan memanfaatkan *fully-connected layer*. Jumlah lapisan yang digunakan dalam arsitektur CNN dapat berkisar antara 2-5 untuk kasus yang tidak terlalu banyak data untuk menghindari gejala *overfitting* jika model dilatih terlalu lama/dalam. Dalam penerapan ini, digunakan hanya 4 lapisan yang masing-masingnya terdiri dari beberapa tahap seperti lapisan konvolusi dengan *input channel* awal berupa 1 (*grayscale*), penerapan *batch normalization*, fungsi aktivasi non-linear ReLu, dan penerapan *max pooling*. Setiap lapisan konvolusi diterapkan *kernel* dengan ukuran 3x3, *padding* berukuran 1, dan *stride* berukuran 1. Sedangkan, penerapan ukuran *kernel* dan *stride* pada lapisan *pooling* masing-masing adalah 2. Ukuran *feature map* di setiap akhir lapisan akan meningkat seiring terjadinya penurunan resolusi spasial.

Setelah melalui lapisan CNN, arsitektur model akan dilanjut dengan susunan RNN menggunakan GRU. Penerapan GRU pada kasus ini dirasa lebih sesuai dibandingkan penggunaan LSTM, karena mempertimbangkan jumlah parameter yang lebih sedikit untuk dataset audio yang tidak terlalu banyak sehingga gejala *overfitting* dapat dihindari. Penggunaan mekanisme *bi-directional* ditujukan agar model mampu memahami makna atau konteks informasi dalam dua arah temporal (sebelum dan setelah momen tertentu) (Su et al., 2024). Berikut adalah deskripsi lengkap dari perubahan dimensi data sepanjang melewati lapisan-lapisan konvolusi dan jumlah parameter yang tersedia.

Tabel III.2 Susunan arsitektur CRNN dan perubahan dimensi data

No	Jenis Lapisan	Ukuran <i>Input</i>	Ukuran <i>Output</i>	Jumlah Parameter
Lapisan CNN				
0.	<i>Input</i> log-Mel spektrogram	(1,128,216)	(1,128,216)	0
1.	Lapisan konvolusi ke-1	(1,128,216)	(32,128,216)	320
2.	<i>Batch Normalization</i> ke-1	(32,128,216)	(32,128,216)	64
3.	<i>Maximum Pooling</i> ke-1	(32,128,216)	(32,64,108)	0
4.	Lapisan konvolusi ke-2	(32,64,108)	(64,64,108)	18.496
5.	<i>Batch Normalization</i> ke-2	(64,64,108)	(64,64,108)	128
6.	<i>Maximum Pooling</i> ke-2	(64,64,108)	(64,33,55)	0
7.	Lapisan konvolusi ke-3	(64,33,55)	(128,33,55)	73.856

No	Jenis Lapisan	Ukuran <i>Input</i>	Ukuran <i>Output</i>	Jumlah Parameter
8.	<i>Batch Normalization</i> ke-3	(128,33,55)	(128,33,55)	256
9.	<i>Maximum Pooling</i> ke-3	(128,33,55)	(128,16,27)	0
10.	Lapisan konvolusi ke-4	(128,16,27)	(256,16,27)	295.168
11.	<i>Batch Normalization</i> ke-4	(256,16,27)	(256,16,27)	512
12.	<i>Maximum Pooling</i> ke-4	(256,16,27)	(256,8,13)	0
Lapisan RNN (BiGRU)				
13.	<i>Permute</i>	(256,8,13)	(13,256,8)	0
14.	<i>Reshape</i>	(13,256,8)	256×8	0
15.	BiGRU lapisan ke-1 dan 2	(13, 2048)	(13,256)	± 2.63 juta
16.	Pemilihan <i>time step</i> terakhir	(13,256)	256	0
17.	<i>Fully connected linear</i>	256	50	12.850
Total Parameter				$\pm 3,03$ juta

Teknik *permute* dan *reshape* perlu dilakukan sebelum data memasuki model RNN untuk memudahkan model tersebut dalam membaca dimensi waktu. Di akhir lapisan CRNN dan sebelum *classifier*, teknik regularisasi *Dropout* diterapkan sebesar 30% untuk mengurangi ketergantungan satu neuron pada neuron kuat lainnya sehingga diharapkan setiap neuron dapat menggunakan seluruh kapasitas prediksinya dengan konsisten dan mempelajari fitur yang lebih kuat.

III.2.2 ResNet-18 Mel-Spec

ResNet-18 yang digunakan sebagai model pembandingan *baseline* terdiri dari beberapa tahap utama, seperti *input*, lapisan konvolusi pertama, *max pooling*, lapisan ke-1 hingga ke-4 yang masing-masingnya terdiri dari dua *basic block*, kemudian dilengkapi dengan *global average pooling* yang akan diakhiri dengan lapisan *fully connected* untuk menentukan 50 kelas suara. Setiap *basic block* terdiri dari dua lapisan konvolusi yang diikuti dengan teknik *batch normalization* dan aktivasi non-linear ReLU (hanya setelah BN yang pertama). Jika seluruh *basic block* ini dijumlahkan, maka total seluruh lapisan yang ada pada ResNet ini bisa mencapai 18 lapisan yang memiliki parameter sebanyak kurang lebih 11 juta parameter. Pada *basic block* lapisan ke-2 hingga ke-4, terdapat mekanisme *downsampling*, yaitu teknik yang digunakan ketika *input* dan *output* memiliki ukuran *channel* yang berbeda sehingga tidak dapat dijumlahkan (*shortcut connection*). Sementara itu, *adaptive average pool* digunakan untuk meringkas *feature map* (agregasi) menjadi hanya dalam bentuk satu angka untuk mengurangi dimensi spasial dari fitur yang telah diekstraksi pada lapisan sebelumnya. Secara garis besar, ResNet menerapkan penggunaan lapisan konvolusi dan *classifier* yang sama seperti CRNN sebelumnya, tetapi dengan kompleksitas yang lebih tinggi karena

melibatkan lebih banyak lapisan dan mekanisme *residual skip connection*. Berikut adalah ringkasan arsitektur ResNet-18 yang diterapkan dalam eksperimen ini.

Tabel III.3 Susunan arsitektur ResNet-18 dan perubahan dimensi data

Jensi Lapisan	Ukuran <i>Output</i>
<i>Input</i> log-Mel spektrogram	(1,128,216)
Konvolusi 1 + BN + ReLU	(64,64,108)
<i>Max pooling</i>	(64,32,54)
<i>Layer</i> 1 (2 <i>basic block</i>)	(64,32,54)
<i>Layer</i> 2 (2 <i>basic block</i>)	(128,16,27)
<i>Layer</i> 3 (2 <i>basic block</i>)	(256,8,14)
<i>Layer</i> 4 (2 <i>basic block</i>)	(512,4,7)
<i>Adaptive average pool</i>	(512,1,1)
<i>Flatten</i>	512
<i>Fully-connected layer</i>	50

III.2.3 ViT Audio

Arsitektur *Vision Transformer* yang digunakan dalam eksperimen kali ini merupakan model ViT-B/16 (*Base*, *patch size* 16). Walaupun diterapkan dalam tugas klasifikasi audio yang sama, ViT memiliki mekanisme kerja yang jauh berbeda dengan dua model sebelumnya. Data audio harus terlebih dahulu dikonversi dalam bentuk representasi dua dimensi (log-Mel spektrogram) yang kemudian perlu diubah menjadi 3 *channel* dan diterapkan *patch embedding* untuk membagi-bagi visual spektrogram menjadi potongan yang lebih kecil, dalam hal ini berukuran 16 x 16 piksel (Luo et al., 2022). *Patch* tersebut diubah dalam bentuk token sekuensial (*flattened*) yang akan dimasukkan pada 12 lapisan *transformer encoder* yang dilengkapi dengan proses *self-attention* untuk memperoleh token CLS diujung proses. Di akhir, data akan masuk pada *dense layer* untuk dilakukan tugas klasifikasi yang dapat menghasilkan keluaran berupa nilai probabilitas dari setiap target audio. Secara keseluruhan, arsitektur ini memiliki total sekitar 86 juta parameter dengan dimensi embedding setiap *patch*-nya adalah 768. Dalam setiap *encoder block*, terdiri dari *layer normalization*, *self-attention* berupa *multi-head attention*, dan MLP. Berikut adalah ringkasan arsitektur ViT Audio yang digunakan dalam eksperimen sebagai model pembanding SoTA.

Tabel III.4 Susunan arsitektur ViT Audio dan perubahan dimensi data

Jensi Lapisan	Ukuran <i>Output</i>
<i>Input</i> log-Mel spektrogram	(1,128,216)

Jensi Lapisan	Ukuran <i>Output</i>
<i>Patch embedding</i> (16 x 16)	$N \times 768$
<i>Transformer encoder</i> ke-1	$(N + 1) \times 768$
...	$(N + 1) \times 768$
<i>Transformer encoder</i> ke-12	$(N + 1) \times 768$
Ekstraksi token CLS	768
<i>Linear classification</i>	50

III.3 Hyperparameter

Hyperparameter merupakan parameter yang telah ditentukan sebelum proses pelatihan model dilakukan dan nilai yang diterapkannya pasti berbeda-beda dalam setiap model dan tahap. *Hyperparameter* yang digunakan dalam eksperimen kali ini akan dikategorikan menjadi *hyperparameter* pada dataset, tahap prapemrosesan, tahap pelatihan, *hyperparameter* yang melekat pada arsitektur setiap model.

Tabel III.5 Daftar *hyperparameter* yang digunakan sebelum pelatihan model

Kategori	<i>Hyperparameter</i>	Nilai
Tahap prapemrosesan	<i>Sample rate</i>	22.050 Hz
	<i>n-fft</i>	1.024
	<i>hop length</i>	512
	<i>n-mels</i>	128
	<i>Frequency masking</i>	15
	<i>Time masking</i>	40
	<i>Cross-validation</i>	5-fold
Tahap pelatihan model	<i>Batch size</i>	32
	<i>Learning rate</i>	0,001
	<i>Epochs</i>	50
	<i>Optimizer</i>	Adam
	<i>Loss Function</i>	<i>Cross Entropy Loss</i>
Model CRNN	<i>CNN layer</i>	4
	<i>CNN filter</i>	32-64-128-256
	<i>Kernel size</i>	3 x 3
	<i>Hidden size</i>	128
	<i>Pooling size</i>	2 x 2
	<i>GRU layer</i>	2
	<i>Dropout</i>	0,3
	<i>Output class</i>	50

Hyperparameter yang diterapkan pada model ResNet-18 dan ViTAudio selebihnya memiliki sebagian besar spesifikasi yang sama dengan model CRNN atau tahap-tahap di Tabel III.5.

III.4 Kondisi Pelatihan Model

Setiap model pada saat pelatihan dirancang untuk memiliki kondisi yang sama mulai dari lingkungan eksperimen atau dukungan *hardware*, *framework*, tahap prapemrosesan data, dan keserasian metrik evaluasi untuk menciptakan hasil analisis model yang sepadan (*fair comparison*).

1. Lingkungan eksperimen terdiri dari bahasa pemrograman Python 3.12, penggunaan akselerator dengan tipe GPU NVIDIA Tesla T4 x 2 dari *platform* Kaggle Notebook, dengan memori GPU 15GB/GPU, total RAM sistem sebesar 30 GB, dan penyimpanan disk 57,6 GB. Proses eksekusi setiap *cell* dilakukan di dalam *cloud* milik Kaggle.
2. *Framework* yang digunakan adalah PyTorch dengan versi 2.11.0+cpu.
3. Tahap prapemrosesan data dilakukan dengan membagi data menjadi data latih, validasi, dan uji melalui *fold* yang sudah ditetapkan dari dataset asli.
4. Strategi evaluasi yang diterapkan adalah melalui metrik akurasi, presisi, *recall*, dan F1-score, serta waktu pelatihan dan inferensi. Selain itu, diterapkan pula metrik visual seperti *confusion matrix* untuk menilai pola kekeliruan prediksi antarkelas, RSM untuk menilai kemampuan model dalam mengklasifikasi suara yang mirip, dan analisis *saliency/attention* untuk melihat fokus model dalam proses klasifikasi.

IV. Hasil Benchmarking

Kegiatan membandingkan model dapat dilakukan berdasarkan hasil keluaran metrik evaluasi, kurva pelatihan dan validasi, serta visualisasi *confusion matrix* dari ketiga model yang digunakan. Berikut adalah hasil perbandingan dari model utama CRNN serta kedua model pembandingnya, ResNet-18 dan ViT Audio.


Tabel IV.1 Hasil metrik evaluasi (akurasi, presisi rata-rata, *recall*, F1-score)

Model	Metrik Evaluasi				
	<i>Test Loss</i>	<i>Test Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
CRNN	3,3777	11,75%	0,07	0,12	0,07
ResNet-18	2,4807	38,25%	0,37	0,38	0,33
ViT Audio	3,8397	4,75%	0,01	0,05	0,01


Tabel IV.2 Hasil perbandingan metrik evaluasi lainnya

Model	Metrik Evaluasi				
	<i>Batch size</i>	<i>Epoch Total</i>	<i>Best Epoch</i>	Jumlah Parameter	Waktu Inferensi (ms)
CRNN	32	50	48	2.370.802	413,412
ResNet-18	32	50	41	11.195.890	376,569
ViT Audio	8	15	15	85.837.106	788,8094


Selain perbandingan metrik evaluasi, berikut disajikan gambar kurva pelatihan dan validasi serta visualisasi *confusion matrix* dari setiap model.



Gambar IV.1 Kurva pelatihan dan validasi model utama CRNN




Gambar IV.2 Kurva pelatihan dan validasi model Pembanding *baseline* ResNet-18 Mel-Spec



Gambar IV.3 Kurva pelatihan dan validasi model Pembanding SoTA ViT Audio

Dari ketiga model tersebut, masing-masing menggambarkan kondisi performa yang pada saat pelatihan dan validasi model. Pada Gambar IV.1, *training loss* memiliki tren yang menurun seiring bertambahnya *epoch* meskipun kondisinya belum stabil, *loss* dapat meningkat atau menurun secara drastis. Sementara itu, *validation loss* terlihat menurun dengan lebih stabil, tetapi tidak secepat pada saat pelatihan. Penurunan kedua mode ini menunjukkan bahwa model mampu belajar secara bertahap tanpa adanya indikasi *overfitting* yang kuat. Jika dilihat dari akurasi, model menunjukkan peningkatan akurasi yang baik, tetapi belum sepenuhnya konvergen. Konvergensi ini dapat diraih lebih baik kemungkinan jika menambah jumlah *epoch* untuk memperkuat pelatihan model. Akurasi pada saat *training* yang berfluktuasi tersebut dapat terjadi akibat adanya penerapan teknik augmentasi di awal sehingga dapat membuat model menjadi bingung selama pembelajaran, atau ukuran dataset ESC-50 yang cenderung kecil. Pada Gambar IV.2, adanya ketidakstabilan pada saat proses validasi yang menunjukkan bahwa model mulai menghafal data di awal, tetapi dapat menurun seiring berjalannya *epochs*. Selisih antara akurasi pada saat pelatihan dan validasi juga terbilang cukup besar. Hal ini menandakan bahwa adanya gejala *overfitting* ringan hingga sedang. Walaupun begitu, di antara ketiga model, ResNet-18 memiliki akurasi yang paling tinggi dalam menjalankan tugas klasifikasi suara lingkungan ESC-50. Berbeda dengan kinerja ViT Audio, proses pelatihan dan validasi terlihat bermasalahan karena adanya fluktuasi yang besar di antara *training loss* dan *validation loss*, serta begitu pula dengan akurasi yang sangat rendah kenaikannya. Hal ini menunjukkan bahwa model belum mampu belajar menangkap pola dari data yang kemungkinan disebabkan oleh kurangnya dataset di tengah kompleksnya arsitektur yang

digunakan, perbedaan domain pada saat *pretrained* dengan ImageNet dengan saat divalidasi di dunia nyata, atau bahkan dapat disebabkan oleh arsitektur model yang terlalu kompleks sehingga sulit mencapai kestabilan kemampuan representasi yang sebenarnya.




Gambar IV.4 *Confusion matrix* dari model utama CRNN (kiri), model *baseline* Resnet-18 (tengah), dan model SoTA ViT Audio (kanan)

Berdasarkan Gambar IV.4, *confusion matrix* menunjukkan kemampuan setiap model dalam memprediksi 50 kelas dengan benar. Dari ketiga model yang diuji, ResNet-18 memiliki pola diagonal yang paling tegas, menandakan bahwa model ini mampu melakukan tugas klasifikasi kelas sebagian besar dengan benar. Hal ini sejalan dengan penurunan *loss* dan peningkatan akurasi yang lebih unggul sebelumnya. Berbeda dengan CRNN dan ViT Audio, keduanya belum secara optimal melaksanakan tugas prediksi. Walaupun CRNN sedikit mampu memberikan garis diagonal yang samar, kemampuannya masih tetap sering tertukar dalam memprediksi antarkelas. Kemampuannya dalam memprediksi kelas yang cenderung benar (persentase berhasil diprediksi berkisar antara 50-100%) hanya termasuk pada kelas *dog* (50%), *rain* (60%), *thunderstorm* (80%), *mouse click* (90%), *glass breaking* (60%), dan *airplane* (60%). Beberapa kelas lainnya diprediksi dengan keliru, seperti misalnya suara *vacuum cleaner* diprediksi sebesar 90% sebagai suara *rain*, suara *sneezing* dan *rooster* dianggap 90% hingga 100% sebagai suara *glass breaking*. Sementara pada ViT Audio, hanya terdapat beberapa kelas yang dominan diprediksi dari beberapa kelas yang berbeda, seperti di bagian kiri (*frog*), kanan (*keyboard typing* dan *train*), sedangkan kelas lainnya tidak diprediksi sama sekali. Hal ini menunjukkan bahwa model belum sepenuhnya memahami perbedaan antarkelas dan ini sejalan dengan akurasi model pada saat pengujian yang memang

sangat rendah. ViT merupakan model yang paling gagal dalam mempelajari representasi yang beragam dalam kasus klasifikasi audio ini karena hasil prediksinya hanya terkonsentrasi di beberapa kelas saja.

V. Analisis RSM

Analisis RSM akan meninjau dari sisi lapisan *penultimate*, yaitu lapisan sebelum data masuk ke lapisan *classifier* untuk melihat cara model dalam menebak kelas tertentu. Matriks berikut menggambarkan hasil representasi fitur setiap model dengan terstruktur dengan setiap pikselnya menunjukkan tingkat kemiripan antara dua sampel.




Gambar V.1 Visualisasi *representation similarity matrix* dari model model utama CRNN (kiri), model baseline Resnet-18 (tengah), dan model SoTA ViT Audio (kanan)

Ketiga model menunjukkan jelasnya pola kemiripan yang ditandai dengan garis diagonal yang tegas. Namun, model CRNN masih memiliki beberapa blok yang gelap di sekitar garis diagonal utama. Hal ini menandakan bahwa masih terdapat pola *noise* yang mengganggu dalam representasi kemiripan antara dua sampel dan sejalan pula dengan pola *confusion matrix* yang masih banyak kesalahan atau hasil prediksi yang *overlap* antarkelas. Hal yang sama juga terjadi pada model ViT dengan masih banyaknya pola gelap di sekitar diagonal utama dan garis diagonal yang tidak cukup jelas dibandingkan dua model lainnya. Model ViT masih menganggap banyak sampel yang memiliki representasi yang mirip walaupun berasal dari kelas yang berbeda sehingga kemampuannya dalam memprediksi kelas tertentu juga menjadi terhambat. Dari ketiga model, model ResNet-18 memiliki kemampuan membedakan antarkelas yang paling baik dan

menunjukkan kemiripan kelas yang sama dengan tegas. Area di sekitar diagonal utama menunjukkan warna yang lebih terang. Namun, ada beberapa blok berwarna gelap yang terakumulasi di bagian kiri atas, menunjukkan bahwa beberapa kelas yang berbeda masih dianggap sebagai kelas yang sama.


VI. Analisis *Saliency*

Analisis *saliency* ditujukan untuk meninjau fokus model dalam memperhatikan pola suara yang berbeda dalam bentuk visualisasi spektrogram juga dan membandingkannya dengan bentuk spektrogram asli. Idealnya, bentuk *saliency* yang baik berfokus pada bagian spektrogram yang mengandung informasi (berwarna terang) juga. Warna terang pada visualisasi *saliency* menandakan kontribusi bagian yang paling tinggi dalam memengaruhi keputusan model. Pada analisis ini dipilih dua sampel dan 13-20 sampel yang dianggap paling representatif terhadap kebenaran uji model CRNN, yaitu sample kelas *dog*, *vacuum cleaner*, dan *rain*.




Gambar VI.1 Visualisasi *saliency* sampel ke-1 (*class dog*, kiri) dan ke-9 (*vacuum cleaner*, kanan) dari model utama CRNN

Pada Gambar VI.1, model CRNN memberikan fokus dengan samar pada bagian yang mengandung informasi suara impulsif dari *dog* di bagian kiri bawah, tetapi juga memberikan fokus di akhir waktu. Model CRNN ini menangkap pola frekuensi dengan cukup baik. Sementara itu, pada pola *vacuum cleaner* yang tersebar sepanjang waktu dengan kondisi frekuensi rendah yang cukup dominan, CRNN memberikan fokus hanya pada akhir suara saja. Kedua contoh dari kelas *dog* dan *vacuum cleaner* dengan fokus di akhir dapat disebabkan oleh penggunaan RNN tipe BiGRU yang mayoritas memiliki kontribusi besar di akhir sinyal suara karena proses *backward pass* yang dilakukannya. Walaupun memang seperti itu kinerja BiGRU dengan fokus di akhir suara saja, model ini masih belum dapat mengikuti seluruh pola suara dari mesin *vacuum cleaner*.



Gambar VI.2 Visualisasi *saliency* sampel ke-1 (*class dog*, kiri) dan ke-9 (*vacuum cleaner*, kanan) dari model *baseline* ResNet-18

Berbeda dengan *saliency* ResNet-18 pada Gambar VI.2, fokus utama model benar-benar tercermin dari informasi suara aslinya. Pada sampel kelas *dog*, *saliency* yang ditunjukkan terkonsentrasi di bagian suara *dog* di ujung kiri bawah, sedangkan pada sampel kelas *vacuum cleaner*, fokus model menyebar ke seluruh bagian pola suara yang kontinu. Hal ini menunjukkan bahwa ResNet018 mampu mengekstraksi fitur dengan lebih spesifik deibandingkan CRNN.



Gambar VI.3 Visualisasi *saliency* sampel ke-1 (*class dog*, kiri) dan ke-10 (*rain*, kanan) dari model SoTA ViT Audio

Pada model ViT Audio, *saliency* kelas *dog* terkonsentrasi pada bagian sumber informasi, tetapi juga terdapat bentuk grid di seluruh spektogram. Persebaran aktivasi ini menunjukkan bahwa model juga memperluas perhatiannya tidak hanya pada sinyal utama atau kemunculannya disebabkan oleh penerapan mekanisme *patch* 16 x 16 sebelumnya. Sementara itu, pada kelas *rain*, *saliency* yang diberikan model juga tersebar ke seluruh durasi waktu, menyesuaikan dengan pola hujan yang bersifat acak dan kontinu. Namun, penyebaran ini menandakan bahwa model belum bisa memberikan fokusnya secara optimal untuk satu kelas tertentu (sifat diskriminatif belum tercapai). Kondisi ini sejalan dengan hasil pelatihan, validasi, dan *confusion matrix* sebelumnya.

VII. Diskusi Komparatif

Pada bagian ini, perbandingan kinerja model akan ditinjau dari beberapa contoh kasus yang paling mencolok dari setiap model, seperti kemiripan yang tinggi atau rendah dan beberapa contoh kelas yang sering tertukar dalam arsitektur CRNN dan ResNet-18.

Model utama CRNN menunjukkan kemiripan representasi yang tinggi antara kelas *glass breaking* dan *sneezing* pada RSM. Berdasarkan Gygi (2007), pola ini tidak konsisten dengan cara sistem auditori biologis dalam memproses stimulus tersebut. Pada jurnal ini, keduanya dibedakan menjadi suara diskrit bagi *glass breaking* dan suara kontinu bagi *sneezing* atau suara sejenis lainnya yang dihasilkan manusia. Sementara itu, Song et al. (2024) menunjukkan bahwa kemiripan yang dianggap oleh model terhadap suara dari sumber berbeda dapat ditentukan berdasarkan kemiripan pola waktu dan frekuensinya. Implikasi dari kemiripan ini kemungkinan disebabkan oleh fokus CRNN pada pola energi lokal (spektral) dalam spektrogram dibandingkan dengan makna suara yang sebenarnya diinterpretasikan oleh sistem auditori manusia. Dalam hal ini berarti RNN lebih condong dalam mempelajari fitur akustik suara dibandingkan kategori semantiknya.

Dari keseluruhan model yang dilakukan eksperimen, model ResNet-18 memiliki kemampuan yang paling unggul dalam memprediksi kelas suara dibandingkan model CRNN dan ViT. Model ini mampu membedakan jenis suara dari sumber yang berbeda dengan baik. Arsitekturnya yang secara hierarkis terdiri dari 18 lapisan sekuensial membuatnya lebih mudah beradaptasi pada dengan fitur tingkat rendah (seperti suara yang timbul dengan singkat) hingga audio yang spesifik. Cara kerja ini meniru kemampuan otak manusia yang melalui pendekatan hierarkis mulai dari saraf auditori menuju urutan tertinggi dari auditori cortex (Li et al., 2023).

VIII. Penutup

VIII.1 Kesimpulan

Berdasarkan eksperimen yang dilakukan, berikut adalah kesimpulan yang ditemukan berdasarkan tujuan utama penelitian.

1. Pada eksperimen ini, model utama CRNN untuk klasifikasi 50 kelas suara dapat diterapkan walaupun hasil prediksinya belum memuaskan dibandingkan model *baseline* pembandingnya, ResNet-18.

2. Model utama CRNN memiliki performa yang berada di antara model *baseline* ResNet-18 dan model SoTA ViT Audio. Model CRNN mampu menghasilkan representasi suara yang belum cukup baik, ditandai dengan masih kesulitan dalam membedakan suara antarkelas yang memiliki pola spektral yang sama.
3. Kesesuaian representasi internal antar-arsitektur untuk melihat proses pengelompokkan suara dari setiap model belum sepenuhnya terlihat dengan jelas. Beberapa kelas masih dianggap mirip dengan kelas sebenarnya (ditandai dengan blok hitam yang berkumpul di sekitar diagonal utama RSM).
4. Area fokus (atensi) model melalui visualisasi saliency maps pada spektrogram telah divisualisasikan melalui pengambilan 13-20 sampel yang representatif untuk memahami karakteristik frekuensi yang dianggap penting oleh masing-masing arsitektur.

VIII.2 Keterbatasan Penelitian dan Saran

Penelitian yang telah dilakukan masih memiliki beberapa keterbatasan, di antaranya adalah penggunaan dataset ESC-50 yang relatif kecil sehingga arsitektur kompleks ViT belum dapat mengimbangnya secara optimal. Lalu, penelitian ini tidak mencantumkan metrik evaluasi kuantitatif pada analisis RSM dan *saliency*, serta penerapan optimasi *hyperparameter* tidak dilakukan sehingga kemungkinan performa model yang sebenarnya belum dapat dimaksimalkan. Oleh karena itu, penelitian selanjutnya dapat memanfaatkan kombinasi dataset yang lebih luas untuk meningkatkan kemampuan generalisasi model, menerapkan *scheduling* untuk *hyperparameter learning rate* atau teknik optimasi lainnya, dan penggunaan metrik evaluasi yang lebih komprehensif, baik secara kualitatif maupun kuantitatif.

IX. Referensi

- Bansal, A., & Garg, N. K. (2022). Environmental Sound Classification: A descriptive review of the literature. *Intelligent systems with applications*, 16, 200115.
- Conway, C. M., Pisoni, D. B., & Kronenberger, W. G. (2009). The importance of sound for cognitive sequencing abilities: The auditory scaffolding hypothesis. *Current directions in psychological science*, 18(5), 275-279.

- Fadhillah, R. F., & Sumiharto, R. (2023). Klasifikasi Suara Untuk Memonitori Hutan Berbasis Convolutional Neural Network. *IJEIS (Indonesian Journal of Electronics and Instrumentations Systems)*, 13(1), 13-22.
- Giordano, B. L., Esposito, M., Valente, G., & Formisano, E. (2023). Intermediate acoustic-to-semantic representations link behavioral and neural responses to natural sounds. *Nature Neuroscience*, 26(4), 664-672.
- Gygi, B., Kidd, G. R., & Watson, C. S. (2007). Similarity and categorization of environmental sounds. *Perception & psychophysics*, 69(6), 839-855.
- Khan, M. T. I., & Tawhidul, I. (2018). Structural health monitoring by acoustic emission. *Structural Health Monitoring from Sensing to Processing*, 23.
- Li, Y., Anumanchipalli, G. K., Mohamed, A., Chen, P., Carney, L. H., Lu, J., ... & Chang, E. F. (2023). Dissecting neural computations in the human auditory pathway using deep neural networks for speech. *Nature Neuroscience*, 26(12), 2213-2225.
- Luo, J., Yang, J., Chng, E. S., & Zhong, X. (2022). Vision transformer based audio classification using patch-level feature fusion. In *2022 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)* (pp. 22-26). IEEE.
- M. Soni, A. Panda and S. K. Kopparapu, "Generalized SpecAugment: Robust Online Augmentation Technique for End-to-End Automatic Speech Recognition," *2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, Macau, Macao, 2024, pp. 1-5, doi: 10.1109/APSIPAASC63619.2025.10848913.
- Nogueira, A. F. R., Oliveira, H. S., Machado, J. J., & Tavares, J. M. R. (2022). Sound classification and processing of urban environments: A systematic literature review. *Sensors*, 22(22), 8608.
- Park, D. S., & Chan, W. (2019). SpecAugment: A New Data Augmentation Method for Automatic Speech Recognition. *Google AI Blog*.
- Pichler, C., Neumayer, M., Schweighofer, B., Feilmayr, C., Schuster, S., & Wegleiter, H. (2025). Decomposing and Modeling Acoustic Signals to Identify Machinery Defects in Industrial Soundscapes. *Sensors*, 25(16), 4923.
- Piczak, K. J. (2015). ESC: Dataset for environmental sound classification. In *Proceedings of the 23rd ACM international conference on Multimedia* (pp. 1015-1018).
- Ruan, P., Zheng, X., Qiu, Y., & Hao, Z. (2022). A binaural MFCC-CNN sound quality model of high-speed train. *Applied Sciences*, 12(23), 12151.

- Su, Y., Chen, J., Chai, R., Wu, X., & Zhang, Y. (2024). FFA-BiGRU: Attention-Based Spatial-Temporal Feature Extraction Model for Music Emotion Classification. *Applied Sciences*, 14(16), 6866.
- Song, X., Xiong, J., Wang, M., Mei, Q., & Lin, X. (2024). Combined data augmentation on EANN to identify indoor anomalous sound event. *Applied Sciences*, 14(4), 1327.
- Wibowo, A., & Isnain, A. R. (2025). Implementasi Algoritma Machine Learning untuk Klasifikasi Suara Lingkungan: Implementation of Machine Learning Algorithm for Environmental Sound Classification. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 5(2), 616-625.

X. Lampiran

Hasil kerja ini didokumentasikan pada link repositori dalam GitHub sebagai berikut.

<https://github.com/dinagoethe/Audio-Benchmarking-ESC-50>

Model Configuration:

```
model_architecture: 'CRNN'
optimizer: 'Adam'

audio:
  sample_rate: 22050
  n_fft: 1024
  hop_length: 512
  n_mels: 128
  num_classes: 50

training:
  batch_size: 32
  num_epochs: 50
  learning_rate: 0.001

augmentation:
  frequency_mask: 15
  time_mask: 40
```

```
model_architecture: 'ResNet18'
optimizer: 'Adam'

audio:
  sample_rate: 22050
  n_fft: 1024
  hop_length: 512
  n_mels: 128
  num_classes: 50

training:
```

```
batch_size: 32
num_epochs: 50
learning_rate: 0.001

augmentation:
  frequency_mask: 15
  time_mask: 40
```

```
model_architecture: 'VitAudio'
optimizer: 'Adam'

audio:
  sample_rate: 22050
  n_fft: 1024
  hop_length: 512
  n_mels: 128
  num_classes: 50

training:
  batch_size: 8
  num_epochs: 15
  learning_rate: 0.001

augmentation:
  frequency_mask: 15
  time_mask: 40
```

Requirements

```
# Python Environment
python==3.12.13

# Deep Learning Framework
torch==2.10.0+cu128
torchaudio==2.10.0+cu128

# Data Processing
numpy==2.4.6
pandas==2.3.3

# Visualization
matplotlib==3.10.0
seaborn==0.13.2

# Metrics
scikit-learn==1.6.1
```

Sebagian proses penyusunan tugas ini dibantu oleh LLM Notebook LM, Google AI Studio, dan ChatGPT yang diakses pada tanggal 10 Mei 2026 hingga 3 Juni 2026. Saya menggunakan Notebook LM untuk mencari sumber bacaan utama dari buku atau jurnal yang saya tentukan langsung. Lalu, Google AI Studio digunakan untuk menjelaskan konsep lebih detail yang masih

membingungkan jika hanya membaca hanya dari buku dan jurnal saja, serta untuk menuntun saya dalam proses pembuatan kode. Sementara itu, ChatGPT digunakan untuk mendefinisikan istilah yang belum dipahami secara singkat. Seluruh isi laporan ini telah saya tulis ulang disesuaikan dengan pemahaman saya sendiri.